DIPLOMADO EN CIENCIA DE DATOS PARA LAS FINANZAS

Evaluación y Priorización de Controles de Riesgo Operacional mediante Redes Neuronales Artificiales

Trabajo final · Introducción a Modelos de Machine Learning en Finanzas

Autor: Gonzalo Gallardo Alvarado

Docente: Guillermo Yañez

Metodología: aprendizaje supervisado (ANN/MLP)

Octubre de 2026

Estudio académico desarrollado con datos sintéticos.

ENTREGA FINAL | CIENCIA DE DATOS PARA LAS FINANZAS

Modelo de red neuronal artificial para predecir deficiencias y priorizar controles de riesgo operacional

Opción B: redes neuronales | Profesor: Guillermo Yañez | Autor: Gonzalo Gallardo Alvarado | Octubre 2026

Trabajo academico reproducible en Python 3.12. Los datos son sinteticos y no corresponden a información de una institución financiera.

Resumen ejecutivo

Se construyó un sistema reproducible de clasificación binaria que estima la probabilidad de encontrar una deficiencia en la siguiente revisión de un control operacional. Se entrenó una red neuronal multicapa (ANN/MLP) y se comparó contra regresión logística. El proyecto produce métricas fuera de muestra, gráficos diagnósticos, un ranking operativo y la predicción de un nuevo control hipotético. Se emplean 2.400 observaciones sintéticas con resultados estocásticos, de modo que la evaluación es demostrativa, no evidencia de desempeño bancario real.

1. Correspondencia con la pauta

Criterio	Evidencia del trabajo
Originalidad	Caso de uso en riesgo operacional; variables, generador de datos, umbrales y priorización diseñados para el proyecto.
Complejidad	Preprocesamiento mixto, dos capas ocultas, regularización, early stopping, validación temporal, comparación de algoritmos y análisis de importancia.
Funcionalidad	Script ejecutable con F5, generación de CSV/JSON/PNG, predicción de nuevo caso y pruebas automáticas.

2. Problema, objetivo e hipótesis

Pregunta: ¿Las características conocidas antes de una revisión permiten discriminar controles que presentarán deficiencias en su próxima revisión? **Objetivo:** construir y evaluar una ANN para clasificación binaria y ordenar revisiones por probabilidad estimada. **Hipótesis:** los antecedentes previos aportan información predictiva, pero la ANN no necesariamente supera a una alternativa lineal.

3. Datos, trazabilidad y definición de la etiqueta

Se generan 2.400 revisiones hipotéticas con semilla fija 20261022. La etiqueta **deficiencia_siguiente_revision** vale 1 cuando el caso sintético presenta deficiencia y 0 en caso contrario. La etiqueta se genera mediante una función logística con ruido y una extracción Bernoulli: no está codificada como regla determinista ni ingresa entre las variables predictoras.

Variables: criticidad del riesgo (1 a 5), frecuencia mensual, antigüedad del control, hallazgos e incumplimientos previos, días desde última revisión, cambios recientes de proceso, porcentaje de evidencia previa, tipo de

control, área y existencia de un plan previo abierto. Todas se definen como información disponible antes de la revisión objetivo.

Los identificadores de control se reutilizan solo para ilustrar un catálogo. Las observaciones son generadas independientemente, por lo que no representan historiales reales ni deben interpretarse como seguimiento longitudinal verdadero.

4. Metodología

El conjunto se separa por fecha: entrenamiento anterior a julio de 2025 (1.586 casos), validación entre julio de 2025 y enero de 2026 (371) y prueba desde febrero de 2026 (443). El escalamiento numérico, la imputación y la codificación de variables categóricas se ajustan exclusivamente sobre entrenamiento mediante un Pipeline, para evitar filtraciones desde prueba.

ANN: MLPClassifier con 16 y 8 neuronas ocultas, activación ReLU, optimizador Adam, regularización L2 (alpha=0,05), tasa de aprendizaje inicial 0,001, máximo 500 iteraciones y detención temprana. **Comparador:** regresión logística sobre el mismo preprocesamiento. El umbral de cada clasificador se escoge maximizando F1 exclusivamente en validación, no en prueba.

5. Resultados fuera de muestra

Métrica	ANN	Regresión logística
ROC-AUC	0.704	0.719
Average precision	0.575	0.610
Precisión	0.382	0.429
Recall	0.940	0.801
F1	0.543	0.559
Exactitud	0.460	0.569
Brier (menor mejor)	0.199	0.192

El umbral ANN fue 0.225; su matriz de confusión en prueba es [[62, 230], [9, 142]] (filas: clase observada 0/1; columnas: predicción 0/1). La regresión logística superó levemente a la ANN en ROC-AUC (0.719 frente a 0.704); este resultado se conserva sin manipularlo.

6. Interpretación de las métricas

ROC-AUC resume la discriminación entre clases en distintos umbrales. Average precision resume el rendimiento precisión-recall. Recall cuantifica qué fracción de casos con deficiencia fue identificada; precisión indica qué proporción de alertas positivas fue correcta. El Brier evalúa el error cuadrático de las probabilidades. Un recall alto puede implicar numerosos falsos positivos, por lo que el umbral debe vincularse al costo de revisión y a la capacidad operativa.

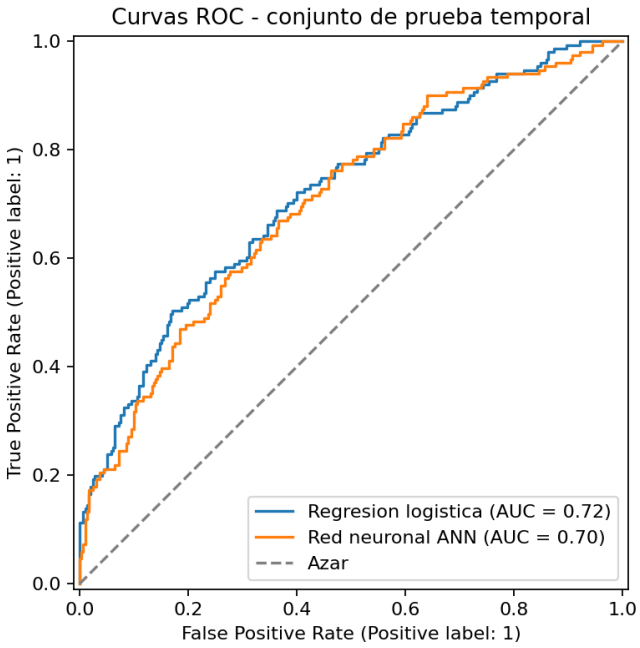


Figura 1. Comparación ROC en prueba

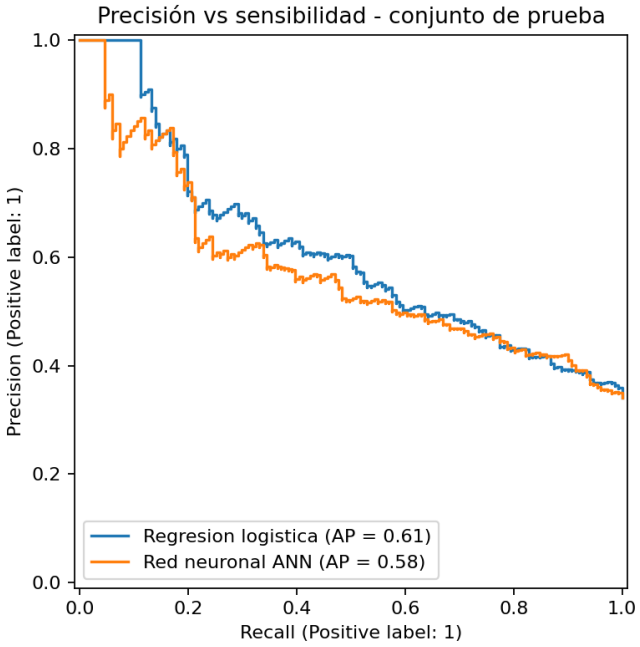


Figura 2. Curvas precisión-recall

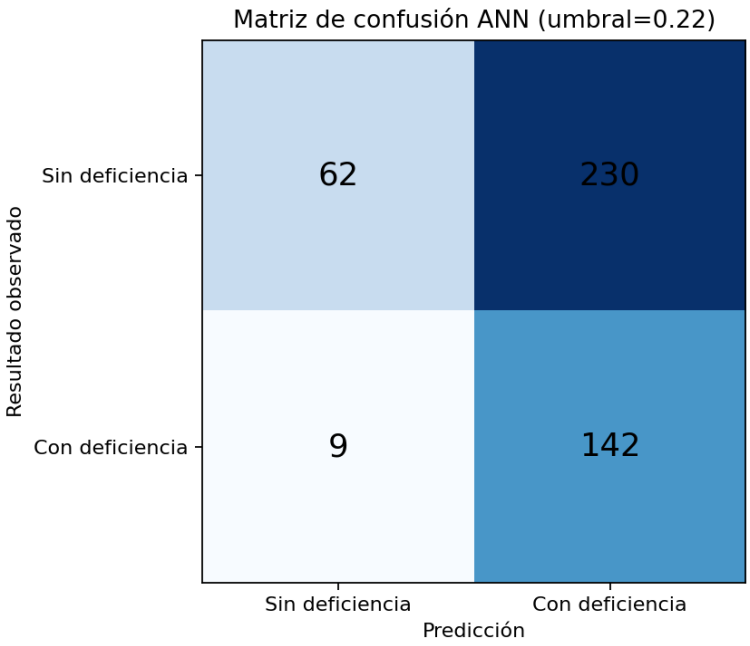


Figura 3. Matriz de confusión ANN

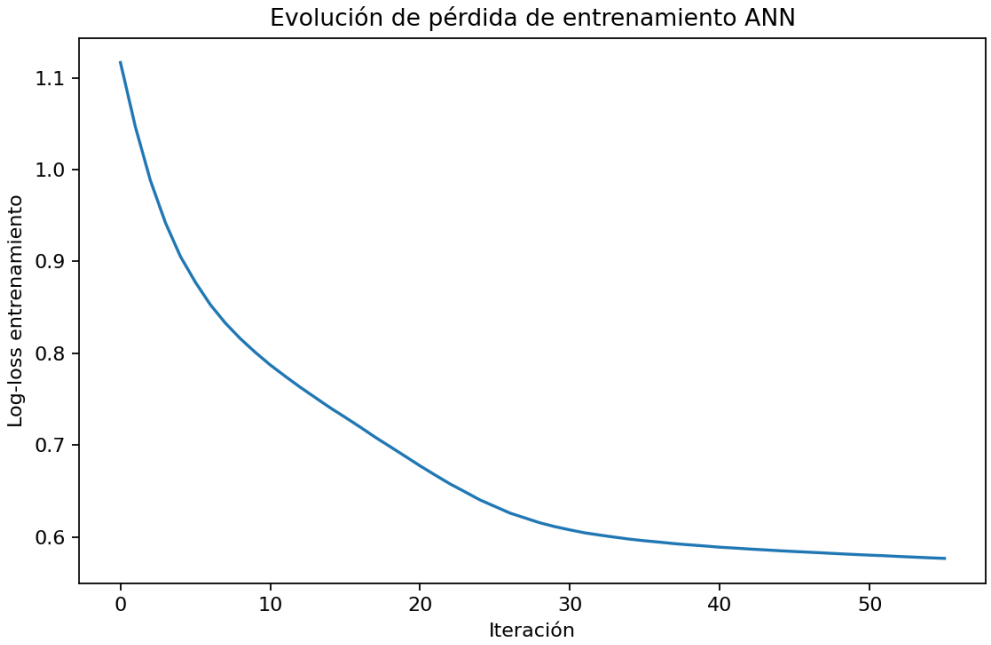


Figura 4. Pérdida durante entrenamiento ANN

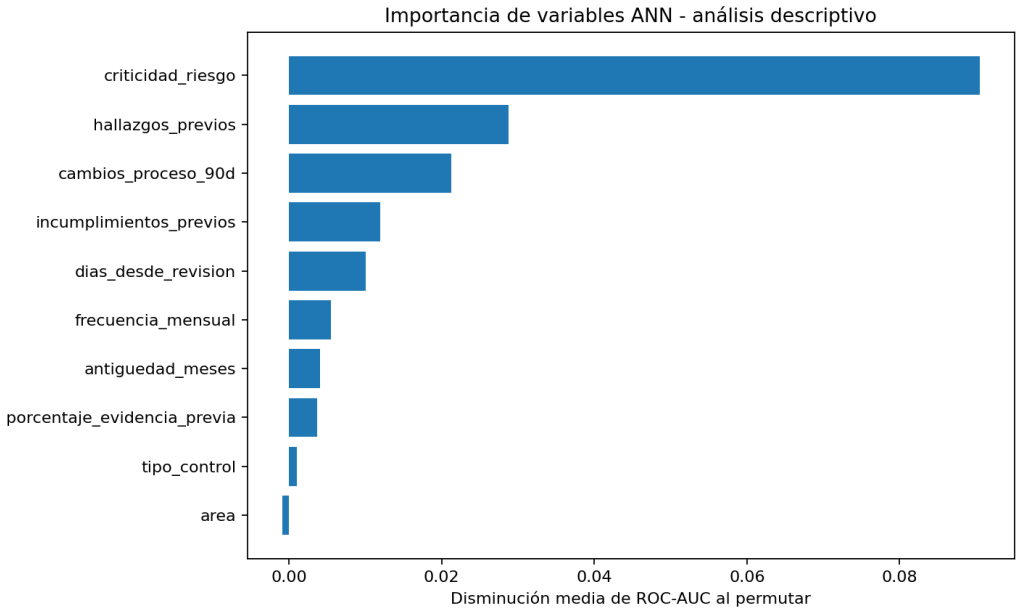


Figura 5. Importancia por permutación

7. Aplicación operativa

El sistema genera un CSV ordenado por probabilidad de deficiencia. Las bandas ilustrativas son: baja por debajo de 35%, media entre 35% y 65%, alta sobre 65%. No son umbrales regulatorios ni políticas bancarias. El caso nuevo muestra que el programa puede aplicar el preprocesamiento y modelo entrenados a una observación no etiquetada. La priorización es apoyo a la revisión, no reemplaza el juicio del analista ni la criticidad de los riesgos.

8. Limitaciones, control de calidad y trabajo futuro

Las relaciones estadísticas y prevalencias provienen de un generador hipotético. La evaluación temporal se hace sobre fechas asignadas sintéticamente; por ello no prueba robustez ante cambios reales de procesos. La importancia por permutación no implica causalidad. Los datos pueden contener observaciones con el mismo identificador de control en distintos conjuntos, sin representar dependencia histórica real. Para un piloto real se necesitarían datos autorizados, una etiqueta definida consistentemente, validación temporal y por entidad, calibración, control de sesgos, monitoreo de deriva y revisión de gobierno de modelos.

9. Reproducibilidad y entregables

El flujo de analisis se ejecuta mediante main.py. Las dependencias se especifican en requirements.txt y se gestionan en un entorno virtual independiente. El modulo modelo_red_neuronal_riesgo_operacional.py genera datos, metricas, figuras y predicciones. El archivo validacion_modelo.py permite verificar reproducibilidad y consistencia.

10. Vinculación con el material de clases

La propuesta utiliza la opción B de la pauta. Recupera de la introducción las nociones de features/labels y entrenamiento/prueba; de redes neuronales, las capas ocultas, activaciones, minimización de pérdida y sobreajuste; y de los ejemplos de Python, la construcción de DataFrames, scikit-learn, comparación cuantitativa y visualización. No se incluyen clustering ni aprendizaje por refuerzo como modelos adicionales porque la pauta

solicita seleccionar una alternativa.

Conclusión

El proyecto cumple su objetivo técnico demostrativo: la ANN se entrena, produce probabilidades, puede evaluarse en observaciones reservadas y genera una priorización reproducible. En este experimento sintético, el comparador lineal obtiene una discriminación ligeramente superior. La conclusión metodológica es que debe evaluarse la complejidad de los modelos con evidencia, y no asumir que una red neuronal es mejor por definición.